

Plan Projet Subjectivity Detection V1

IAFA-tigable - contributors: Oleiwan Joe, Delmote Adrien..

13/01/2024



UE Management de projet

Résumé

Dans le cadre du CLEF 2024, Conferences and Labs of the Evaluation Forum, le laboratoire CheckThat! se concentre sur la Tâche 2, dédiée à l'étude de la subjectivité dans les articles de presse. Notre équipe de Master informatique (IA et Systèmes embarqué) reprend ce projet collaboratif en ciblant l'utilisation de méthodologies basées sur des Modèles de Langage (LLM) et des dictionnaires. Le document fournit un aperçu détaillé du contexte, des techniques et approches de gestion utilisées, soulignant les objectifs du projet ainsi que son organisation.

Mots-clefs

- LLM-
- Recherche-
- Méthodes-
- Détection-
- Objectivité-
- Subjectivité-
- Dictionnaire-
- Développement-
- Désinformation-

Table des matières

I	Contexte	3
II	Objectif du projet et parties prenantes	4
II.1	Objectifs	4
II.2	Parties prenantes	4
II.2.1	UE Management	4
II.2.2	Client	4
II.2.3	Capture du besoin	5
III	Organisation	6
III.1	Organisation globale	6
III.1.1	Organisation du travail	6
III.1.2	Communication	6
III.2	Organisation interne de l'équipe	6
III.2.1	Communication	6
III.2.2	Suivi des tâches	6
III.2.3	Gestion des ressources et de la production	7
IV	La Recherche	8
IV.1	Les méthodes précédemment utilisées et les résultats	8
IV.2	Les modèles d'apprentissage automatique ciblés	8
IV.3	Le prompt engineering	8
V	Le développement	9
VI	Contrôle Qualité	10
VI	État actuel du projet	11
VI	Bilan	12

I – Contexte

Le laboratoire CheckThat! a été organisé pour la 7e fois dans le cadre de CLEF 2024. Notre but est de réaliser la tâche 2 qui consiste à l'identification de la subjectivité. Dans le but de promouvoir l'intelligence artificielle dans la détection de fragments de texte subjectifs dans les articles de presse. La subjectivité est une caractéristique du langage : en prononçant une énoncé, le locuteur exprime simultanément sa position, son attitude et ses sentiments à l'égard de celle-ci, laissant ainsi sa propre empreinte. Selon le laboratoire, une phrase est considérée comme subjective si elle contient plusieurs critères tels que :

- Rapporter explicitement l'opinion personnelle de son auteur ;
- Contenir des expressions sarcastiques ou ironiques ;
- Contenir des exhortations ou des auspices personnels ;
- Contenir des expressions discriminatoires ou dévalorisantes ;
- Contenir des figures de rhétorique explicitement formulées par son auteur pour exprimer son opinion ;
- Contenir une conclusion tirée par son auteur en dépit d'informations factuelles insuffisantes ;
- Contenir des intensificateurs qui peuvent être attribués à son auteur pour exprimer son opinion ;

La tâche propose des corpus composés de 9 530 phrases annotées manuellement, couvrant six langues - arabe, néerlandais, anglais, allemand, italien et turc.

II – Objectif du projet et parties prenantes

II.1 Objectifs

Il s'agira de développer des modèles basés sur de l'apprentissage automatique. Les modèles utilisés pourront s'appuyer sur des technologies de type ChatGPT (large language models), LangChain ou/et sur des technologies à base de dictionnaires et de modèles comme les forêts aléatoires.

Les résultats de différents modèles ou différentes configurations de modèles seront présentés (évaluation de l'efficacité) sur plusieurs jeux de données. Les données fournies sont annotées.

Fonctionnalité minimale : Un modèle apprentissage profond qui marche sur la langue anglaise. Un rapport d'évaluation de la prédiction sera rendu ; plusieurs configurations du modèle seront testés.

Fonctionnalités complémentaires : les différentes langues, différents modèles apprentissage profond ou autre.

II.2 Parties prenantes

II.2.1 UE Management

Présentation de l'UE : Dans le cadre du programme de première année en Master Informatique, l'unité d'enseignement (UE) Management de Projet est l'unité qui encadre le projet de 4 mois que nous prenons en charge dans un aspect de gestion de celui-ci. Cette UE fait partie du bloc " professionnalisation " contenant les UE Projet / Initiation à la recherche (TIR) / Stage.

L'évaluation se fera tout au long de l'UE, avec des travaux que l'on doit aux professeurs de management ; Dates et intitulés des Rendus :

- Dépôt Rendu kick-off : 13 janvier 2024
- Dépôt Plan projet V1 : 17 février 2024
- Dépôt Plan projet V2 : 17 mars 2024
- Dépôt Plan project V3 : 14 avril 2024
- Dépôt Soutenance finale (Transparent) : avant fin avril 2024

II.2.2 Client

Le client est Mme. Josiane Mothe, Professeur en Système d'information, Big Data, Recherche d'information, Exploration d'information et Apprentissage automatique à L'institut de Recherche Informatique de Toulouse (IRIT). Responsable et contributrice à plusieurs projets au cours des années, Professeur Mothe nous a proposé ce sujet sur la détection de la subjectivité pour lutter contre la désinformation du monde actuel.

Nous travaillerons avec Mme Mothe en méthode KanBan en terme de visualisation et adaptation aux objectifs que l'on se fixe au fur et à mesure dans une première phase de recherche, ensuite en méthode Agile en terme de rapidité de travail dans une deuxième phase de développement. Nous aurons des MileStones à fixer dans un temps future, durant lesquelles nous remettrons à Mme Mothe des rapport intermédiaires sur l'avancement du projet. Cette partie sera détaillé dans la section Organisation de ce document.

II.2.3 Capture du besoin

Categorie	ID d'exigence	Criticité (Obligatoire/ Souhaitée/exemple)	Description Exigence	Methode d'acceptation
Recherche Projet	RP001	Obligatoire	Recherche d'informations sur les methodes Large Language Models et Dictionnaire	Texte (synthèses d'articles scientifiques)
Recherche Projet	RP002	Obligatoire	Recherche d'informations sur les méthodes utilisées les années précédentes dans CLEF	Texte (synthèses d'articles scientifiques)
Recherche Projet	RP003	Obligatoire	Recherche d'information sur les détails de la tâche à réaliser	Texte (synthèses d'articles scientifiques)
Recherche Projet	RP004	Obligatoire	Recherche d'information sur le prompt engineering	Texte (synthèses d'articles scientifiques)
Developement Projet	DP001	Obligatoire	Le système doit comporter un modèle basé sur LLM	Test proto/Scripts Test
Developement Projet	DP002	Obligatoire	Le système doit comporter un modèle basé sur dictionnaire	Test proto/Scripts Test
Developement Projet	DP003	Obligatoire	Le système doit comporter une partie fonctionnelle d'évaluation des modèles	Test proto/Scripts Test
Developement Projet	DP004	Obligatoire	Le système doit être capable de détecter si une phrase est subjective ou objective	Test proto/Scripts Test
Gestion de projet	GP001	Obligatoire	La projet devra se dérouler au maximum sur quatre mois à partir de la date de lancement.	Suivi/Bilan

Source : référentiel projet - Lien : [lien github ici](#) —————ATTENTION—————

III – Organisation

III.1 Organisation globale

Nous définissons l'organisation globale comme étant le processus et l'ordonnancement des tâches vis à vis d'un cadre d'échange entre l'équipe de projet et la cliente dans le but d'assurer une bonne réalisation du projet sous la période 4 mois entre le 15 janvier 2024 et fin avril 2024.

III.1.1 Organisation du travail

Nous décomposons notre travail en deux phases :

La première est une phase recherche, dans laquelle nous lisons différents articles scientifiques afin de cerner les anciennes version de ce projet, de voir les méthodes précédemment utilisées et leurs résultats, d'apprendre d'avantage sur la maîtrise des modèles d'apprentissage ciblées, de découvrir de nouveaux aspect liées directement à l'efficience de notre production comme le prompt engineering.

La seconde est une phase de développement des modèles étudiés durant la phase de recherche. Ces modèles vont analyser les données textuelles et essayer de prédire un jugement sur leur subjectivité. Ensuite, nous développerons le système d'évaluation, qui permet de comparer les résultats des modèles construit avec les résultats de l'équipe de recherche CheckThat !.

Ces 2 phases ont pour finalité de donnée un avis sur les modèles explorées dans la détection de la subjectivité.

III.1.2 Communication

Afin d'assurer une bonne communication avec la cliente, il a été conclu pendant la réunion de lancement du projet que des réunions de 5 à 15 minutes seront faites en fin de journées sur chacun des deux jours prévus pour le projet dans la semaine, lundi et mardi, dans l'esprit de la méthode Agile. Ces réunions rapides nous permettent de tenir la cliente informé sur une évolution au détail près du projet et de surmonter toute confusion rencontrée sur les tâches définies de manière incrémentale et établir des décisions en temps optimal.

Nous utilisons une communication par mail hors-réunions selon les besoins de gestion qui peuvent subvenir.

III.2 Organisation interne de l'équipe

III.2.1 Communication

Afin de gérer la communication au sein de l'équipe, nous utilisons une plateforme de messagerie instantanée : Discord. Ce logiciel permet de créer plusieurs canaux textuelles pour différencier entre les tâches discutées, de créer des canaux vocaux pour se réunir à distance et d'assurer une transmission rapide de documents. Le tout est réalisé sous un même serveur de communication.

III.2.2 Suivi des tâches

Outil de visualtion de tâches Trello : Nous décidons d'utiliser un outil de gestion de projet en ligne inspiré de la méthode KanBan : Trello. Il va nous permettre d'indiquer les différentes tâches à faire, les tâches en cours ainsi que les tâches finies, afin d'avoir un réel suivi sur le projet pour l'ensemble des membres du groupe.

Référentiel de structure projet : Nous établissons un document excel qui permet de sauvegarder la structuration de projet au niveau OBS (organisation breakdown structure), PBS (project breakdown structure), WBS (work breakdown structure), diagramme de gantt initiale, diagramme de gantt courant.

III.2.3 Gestion des ressources et de la production

Pour gérer nos ressources et nos productions, nous utilisons un système de contrôle de version distribué populaire : github. Nous utilisons ce système sous un dépôt public pour organiser les ressources, les logs ainsi que le code produit tout au long du projet. Dans le but, que tout le monde puisse accéder facilement aux documents nécessaires ainsi qu'au travail des membres du groupe. GitHub est utilisé pour stocker tous les documents référencés dans le plan projet.

Lien github : https://github.com/fghjklm/Projet_M1_CheckThat-

IV – La Recherche

IV.1 Les méthodes précédemment utilisées et les résultats

CLEF : Conference and Labs of the Evaluation Forum.

Pour orienter notre recherche, nous explorons les méthodes d'apprentissage automatique utilisées par des équipes de recherche participantes au CLEF au cours des années précédentes. En analysant leurs résultats, nous pouvons apprendre et identifier les méthodes les plus pertinentes pour comparer avec notre projet.

IV.2 Les modèles d'apprentissage automatique ciblés

Nous mettons l'accent sur les deux méthodes ciblées par notre projet : LLM et Dictionnaire pour identifier leurs domaines d'application et leurs processus de développement.

IV.3 Le prompt engineering

Les prompts sont des formulations d'instruction aux LLMs pour effectuer des tâches, nous apprenons des notions liées à l'ingénierie des prompt pour perfectionner nos requêtes dans le but de faire du traitement de données.

V – Le développement

En construction - Sera établi dans une version future du Plan Projet.

VI – Contrôle Qualité

En construction

VII – État actuel du projet

POINTEURS

VIII – Bilan

En construction - Sera établi dans la version 3 du Plan Projet.